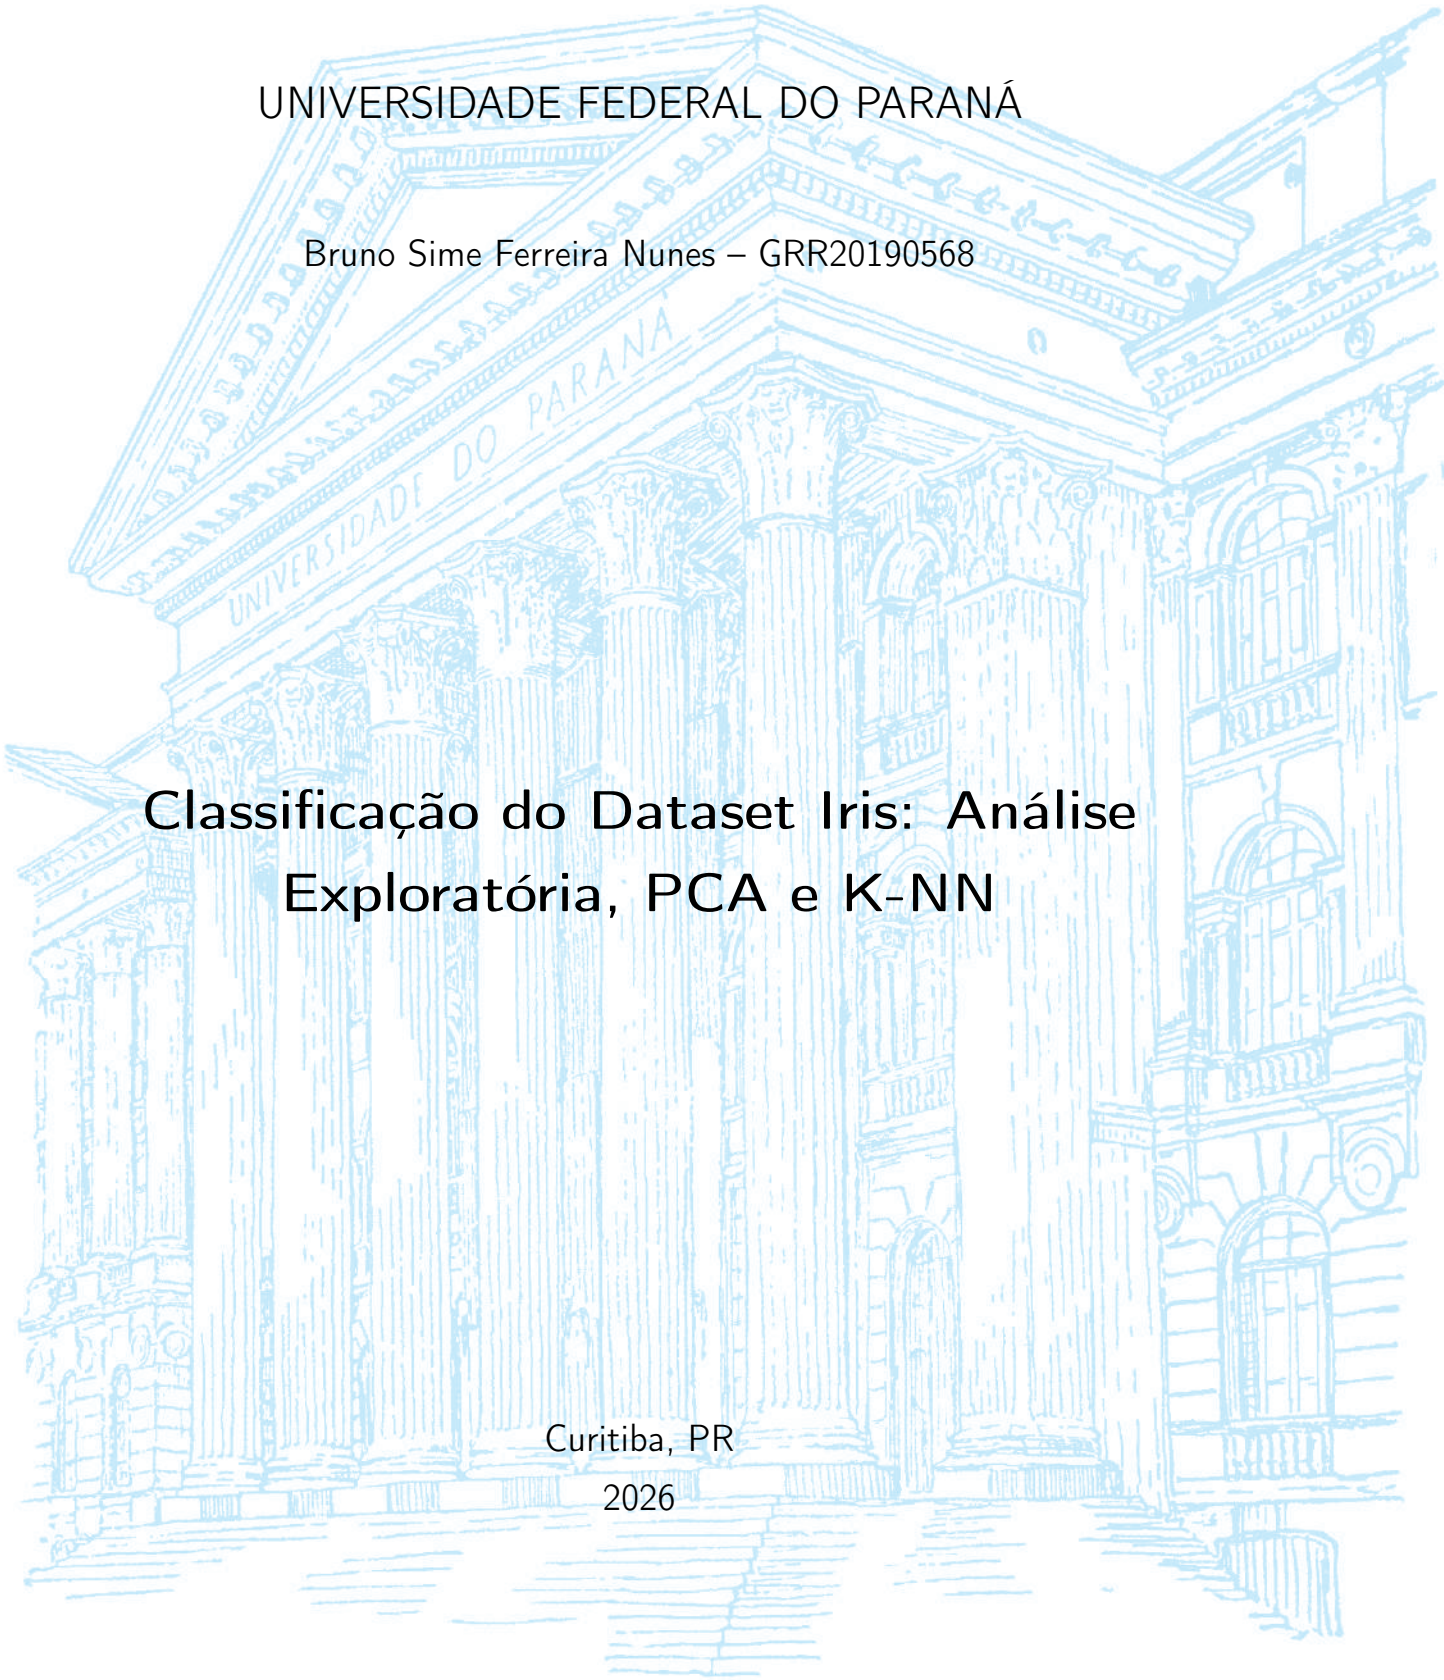
UNIVERSIDADE FEDERAL DO PARANÁ

Bruno Sime Ferreira Nunes – GRR20190568



Classificação do Dataset Iris: Análise Exploratória, PCA e K-NN

Curitiba, PR

2026

Bruno Sime Ferreira Nunes – GRR20190568

Classificação do Dataset Iris: Análise Exploratória, PCA e K-NN

Trabalho acadêmico apresentado como requisito de avaliação na disciplina de Visão Computacional e Percepção da Universidade Federal do Paraná.

Universidade Federal do Paraná (UFPR)
Disciplina de Visão Computacional e Percepção

Orientador: Prof. Eduardo Todt

Curitiba, PR
2026

RESUMO

Este trabalho apresenta uma análise exploratória e experimentos de classificação no conjunto de dados Iris. Foram calculadas estatísticas descritivas gerais e por espécie, analisadas as relações entre comprimento e largura de sépalas e pétalas e estudada a distribuição conjunta das quatro medidas. A Análise de Componentes Principais mostrou que os dois primeiros componentes preservam 95,81% da variância total. Para classificação, os dados foram separados de forma estratificada em 80% para treinamento e 20% para teste. Um classificador K-Nearest Neighbors, com padronização e seleção de k por validação cruzada, obteve 86,7% de acurácia no conjunto de teste. Os resultados confirmam que as medidas de pétala são as mais discriminativas e que os erros se concentram entre as espécies *versicolor* e *virginica*.

Palavras-chave: Iris. classificação. K-NN. análise de componentes principais. aprendizado de máquina.

SUMÁRIO

1 INTRODUÇÃO 7

2 MATERIAIS E MÉTODOS 9
2.1 Conjunto de dados 9
2.2 Estatística descritiva 9
2.3 Análise exploratória e PCA 9
2.4 Classificação com K-NN 10

3 RESULTADOS E DISCUSSÃO 11
3.1 Estatística descritiva 11
3.2 Relação entre comprimento e largura da sépala 12
3.3 Relação entre comprimento e largura da pétala 13
3.4 Distribuição nas quatro dimensões 14
3.5 Análise de Componentes Principais 15
3.6 Classificação com K-NN 16

4 CONCLUSÃO 19

REFERÊNCIAS 21

1 INTRODUÇÃO

O conjunto de dados Iris é um dos exemplos clássicos de classificação estatística. Ele contém 150 observações de flores, divididas igualmente entre as espécies *Iris setosa*, *Iris versicolor* e *Iris virginica*. Cada observação possui quatro medidas contínuas, em centímetros: comprimento e largura da sépala e comprimento e largura da pétala. Não há valores ausentes (FISHER, 1936).

O objetivo deste trabalho é caracterizar estatisticamente essas variáveis, examinar a separação visual das espécies, reduzir a dimensionalidade por Análise de Componentes Principais (PCA) e avaliar a classificação com K-Nearest Neighbors (K-NN). O relatório enfatiza a interpretação dos resultados e mantém o conjunto de teste isolado durante a escolha do modelo.

2 MATERIAIS E MÉTODOS

2.1 CONJUNTO DE DADOS

Foi utilizada a versão do dataset Iris distribuída com a linguagem R, compatível com os registros corrigidos descritos pelo UCI Machine Learning Repository. O conjunto possui 150 amostras e quatro atributos numéricos. Cada classe contém 50 amostras, portanto a frequência relativa de cada espécie é 33,33%.

2.2 ESTATÍSTICA DESCRITIVA

Foram calculadas média, desvio padrão amostral e moda para cada variável, tanto no conjunto completo quanto separadamente por espécie. Como as medidas são contínuas e registradas com uma casa decimal, a moda foi obtida sobre os valores observados; em caso de empate, todos os valores modais foram mantidos.

2.3 ANÁLISE EXPLORATÓRIA E PCA

As relações entre comprimento e largura foram avaliadas com diagramas de dispersão e correlação de Pearson, separadamente para sépalas e pétalas. A distribuição conjunta foi inspecionada por uma matriz de dispersão das quatro variáveis.

PCA transforma as variáveis originais correlacionadas em componentes ortogonais ordenados pela variância explicada (JOLLIFFE; CADIMA, 2016). Antes da decomposição, as quatro medidas foram centralizadas e padronizadas, evitando que diferenças de escala ou dispersão dominassem os componentes.

2.4 CLASSIFICAÇÃO COM K-NN

A divisão foi estratificada, com semente 42: 120 amostras (80%) para treinamento e 30 (20%) para teste, contendo respectivamente 40 e 10 exemplos de cada espécie. Média e desvio usados na padronização foram estimados somente com os dados de treino.

O valor de k foi escolhido por validação cruzada estratificada em cinco partes dentro do conjunto de treinamento. Foram avaliados os valores ímpares de 1 a 15. Somente após essa seleção o modelo foi avaliado no conjunto de teste, preservando a independência da estimativa final.

3 RESULTADOS E DISCUSSÃO

3.1 ESTATÍSTICA DESCRITIVA

Tabela 1 – Estatísticas descritivas gerais das quatro variáveis.

Variável	Média	Desvio padrão	Moda
Comprimento da sépala	5,843	0,828	5,0
Largura da sépala	3,057	0,436	3,0
Comprimento da pétala	3,758	1,765	1,4; 1,5
Largura da pétala	1,199	0,762	0,2

Tabela 2 – Estatísticas descritivas por espécie.

Espécie	Variável	Média	Desvio padrão	Moda
setosa	Comprimento da sépala	5,006	0,352	5,0; 5,1
	Largura da sépala	3,428	0,379	3,4
	Comprimento da pétala	1,462	0,174	1,4; 1,5
	Largura da pétala	0,246	0,105	0,2
versicolor	Comprimento da sépala	5,936	0,516	5,5; 5,6; 5,7
	Largura da sépala	2,770	0,314	3,0
	Comprimento da pétala	4,260	0,470	4,5
	Largura da pétala	1,326	0,198	1,3
virginica	Comprimento da sépala	6,588	0,636	6,3
	Largura da sépala	2,974	0,322	3,0
	Comprimento da pétala	5,552	0,552	5,1
	Largura da pétala	2,026	0,275	1,8

As médias indicam um padrão crescente de tamanho de pétala entre *setosa*, *versicolor* e *virginica*. A largura da sépala não segue a mesma ordem: *setosa* apresenta a maior média. Como as classes são perfeitamente balanceadas, a acurácia não é favorecida por uma categoria majoritária.

3.2 RELAÇÃO ENTRE COMPRIMENTO E LARGURA DA SÉPALA

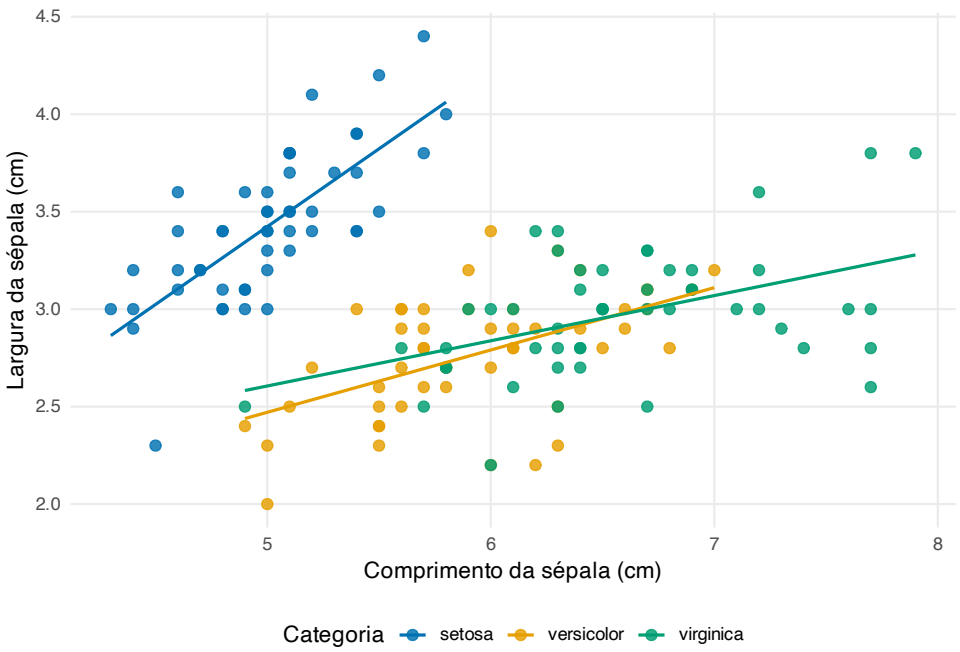


Figura 1 – Comprimento e largura da sépala por espécie.

As correlações de Pearson entre comprimento e largura da sépala foram 0,743 para *setosa*, 0,526 para *versicolor* e 0,457 para *virginica*. Embora sejam positivas dentro de cada espécie, existe sobreposição considerável entre *versicolor* e *virginica*. A espécie *setosa* tende a ter sépalas mais curtas e relativamente mais largas.

3.3 RELAÇÃO ENTRE COMPRIMENTO E LARGURA DA PÉTALA

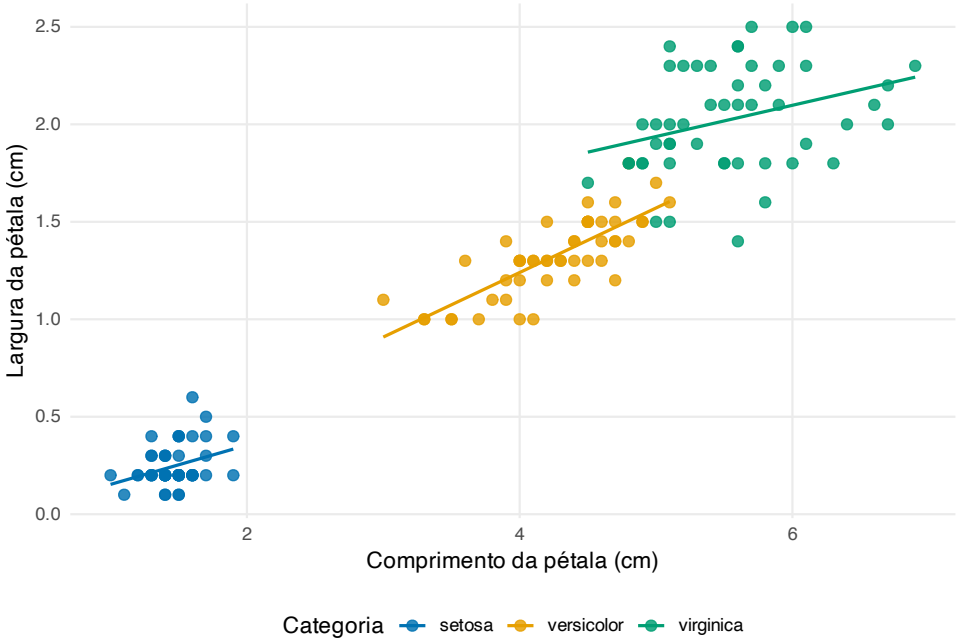


Figura 2 – Comprimento e largura da pétala por espécie.

As correlações entre as duas medidas da pétala foram 0,332 para *setosa*, 0,787 para *versicolor* e 0,322 para *virginica*. A Figura 2 mostra uma separação muito mais clara do que a observada nas sépalas: *setosa* forma um grupo isolado, enquanto *versicolor* e *virginica* mantêm apenas uma pequena região de sobreposição.

3.4 DISTRIBUIÇÃO NAS QUATRO DIMENSÕES

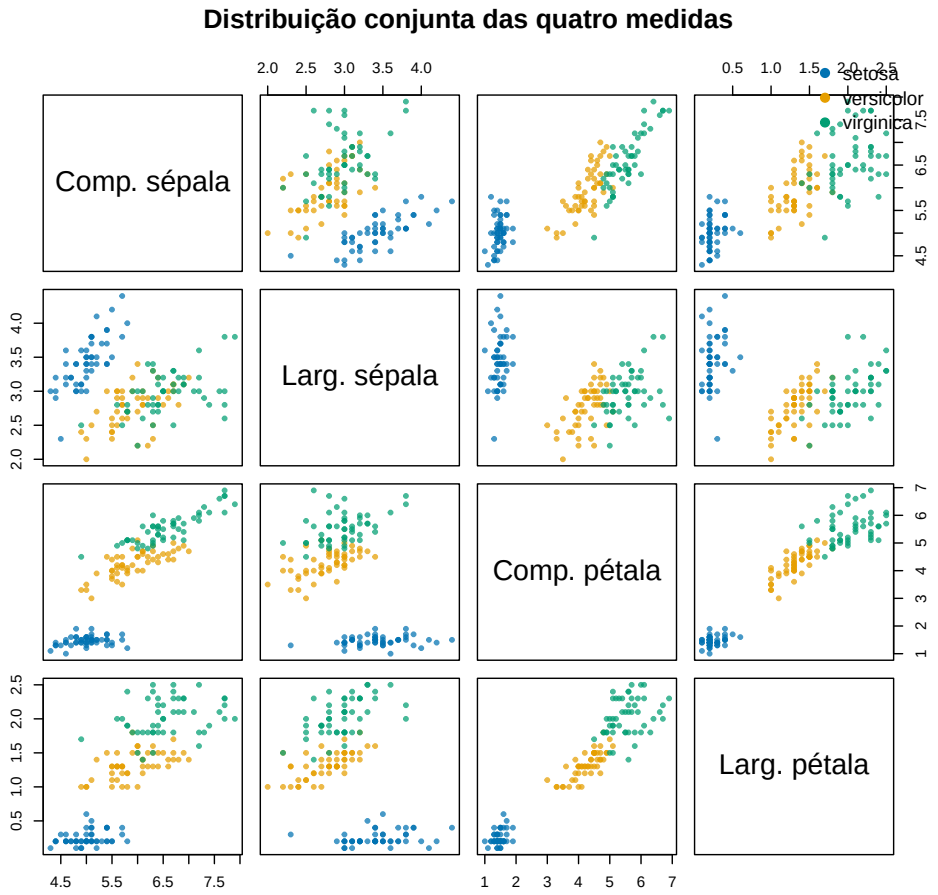


Figura 3 – Matriz de dispersão das quatro variáveis do dataset Iris.

Os pares envolvendo comprimento e largura da pétala são os mais discriminativos. A largura da sépala apresenta a maior sobreposição. A distribuição conjunta confirma que as quatro dimensões contêm informação complementar, mas que grande parte da separação entre as classes está associada às pétalas.

3.5 ANÁLISE DE COMPONENTES PRINCIPAIS

Tabela 3 – Variância explicada pelos componentes principais.

Componente	Variância explicada	Variância acumulada
PC1	72,96%	72,96%
PC2	22,85%	95,81%
PC3	3,67%	99,48%
PC4	0,52%	100,00%

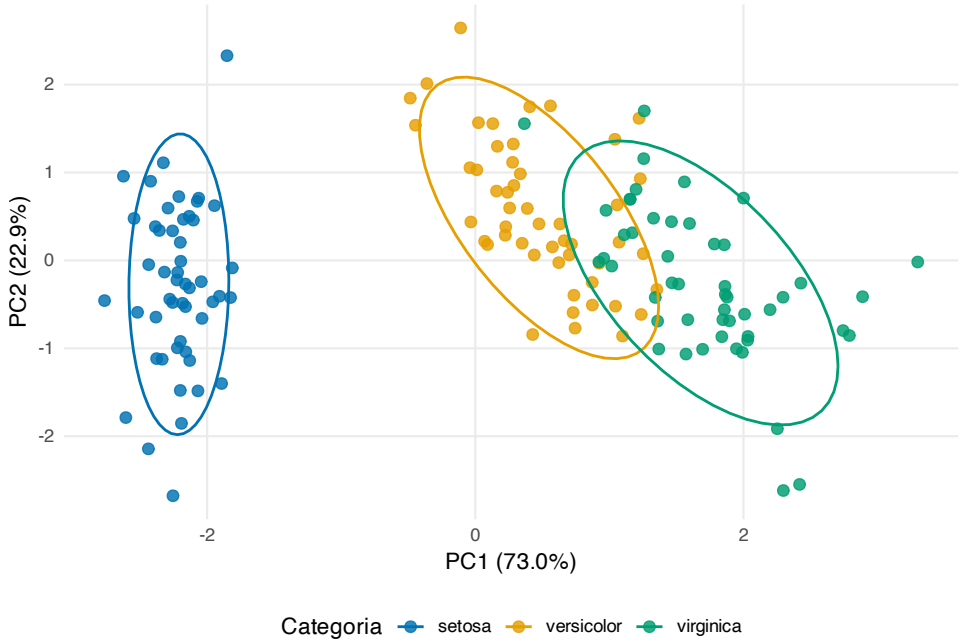


Figura 4 – Projeção das amostras nos dois primeiros componentes principais.

Os dois primeiros componentes preservam 95,81% da variância total, permitindo representar o conjunto em duas dimensões com pouca perda global. O PC1 recebe contribuições elevadas do comprimento da sépala (0,521), comprimento da pétala (0,580) e largura da pétala (0,565), funcionando aproximadamente como um eixo de tamanho. O PC2 é dominado pela largura da sépala ($-0{,}923$). A projeção mantém *setosa* claramente separada e evidencia a proximidade entre *versicolor* e *virginica*.

3.6 CLASSIFICAÇÃO COM K-NN

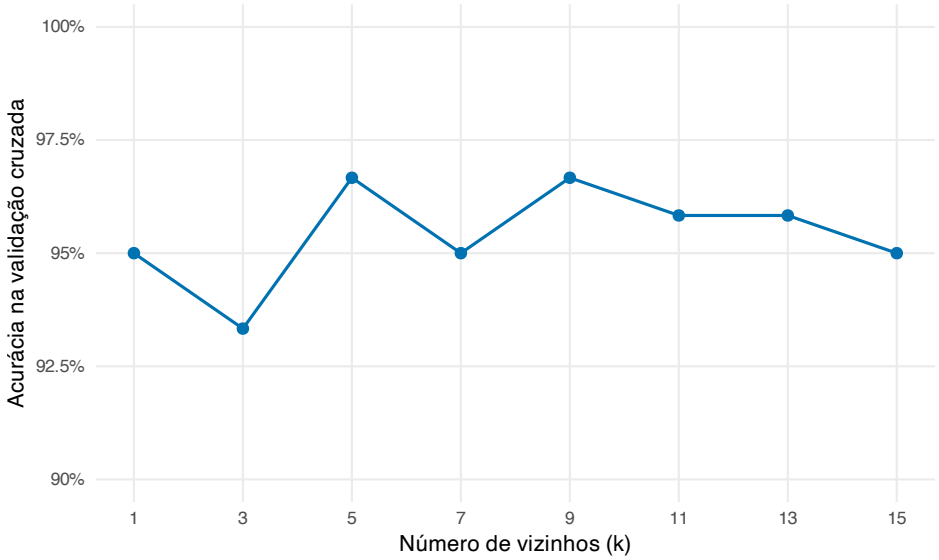


Figura 5 – Acurácia da validação cruzada em função do número de vizinhos.

Os maiores valores de acurácia média na validação cruzada foram obtidos com $k = 5$ e $k = 9$, ambos com 96,7%. Adotou-se $k = 5$, o menor valor entre os empatados. No conjunto de teste, a matriz de confusão foi:

Tabela 4 – Matriz de confusão no conjunto de teste ($n = 30$).

Real / predita	*setosa*	*versicolor*	*virginica*
setosa	9	1	0
versicolor	0	9	1
virginica	0	2	8

Tabela 5 – Métricas por espécie no conjunto de teste.

Espécie	Precisão	Revocação	F1
setosa	1,000	0,900	0,947
versicolor	0,750	0,900	0,818
virginica	0,889	0,800	0,842

O classificador acertou 26 das 30 amostras, resultando em 86,7% de acurácia. Os erros ocorreram sobretudo entre *versicolor* e *virginica*, coerentemente com a sobreposição observada nos gráficos. Houve ainda uma amostra de *setosa* classificada como *versicolor*; devido ao conjunto de teste pequeno, cada erro altera a acurácia em 3,33 pontos percentuais, e o resultado deve ser interpretado como uma estimativa dependente da divisão escolhida.

4 CONCLUSÃO

O dataset Iris é balanceado e apresenta estrutura favorável à classificação. As dimensões das pétalas são as variáveis que melhor distinguem as espécies, enquanto as medidas de sépala, especialmente sua largura, produzem maior sobreposição. A PCA resumiu as quatro variáveis em dois componentes que preservam 95,81% da variância e mantêm a organização visual das classes.

Com divisão estratificada de 80% para treino e 20% para teste, padronização baseada somente no treino e seleção de k por validação cruzada, o K-NN com cinco vizinhos atingiu 86,7% de acurácia. Os resultados mostram que a combinação das quatro medidas permite boa separação, mas também confirmam que *versicolor* e *virginica* constituem o principal desafio de classificação.

REFERÊNCIAS

FISHER, R. A. **Iris** [Dataset]. UCI Machine Learning Repository, 1936. DOI: <https://doi.org/10.24432/C56C76>. Acesso em: 18 out. 2026.

JOLLIFFE, I. T.; CADIMA, J. Principal component analysis: a review and recent developments. **Philosophical Transactions of the Royal Society A**, v. 374, 2016. DOI: <https://doi.org/10.1098/rsta.2015.0202>.

COVER, T.; HART, P. Nearest neighbor pattern classification. **IEEE Transactions on Information Theory**, v. 13, n. 1, p. 21–27, 1967.