T04 — Classificação do dataset Iris

Bruno Sime

18 de outubro de 2026

Sumário

1 Objetivo e dados **1**

2 Estatística descritiva **1**
2.1 Resumo geral 2
2.2 Resumo por categoria 2
2.3 Frequência das categorias 2

3 Relação entre comprimento e largura da sépala **2**

4 Relação entre comprimento e largura da pétala **4**

5 Distribuição conjunta nas quatro dimensões **4**

6 Análise de Componentes Principais (PCA) **6**

7 Classificação com K-NN **7**

8 Conclusão **7**

9 Referências **8**

1 Objetivo e dados

O objetivo é explorar as quatro medidas morfológicas do dataset **Iris**, aplicar Análise de Componentes Principais (PCA) e avaliar um classificador K-Nearest Neighbors (K-NN). O conjunto possui 150 plantas, 50 de cada uma das espécies *setosa*, *versicolor* e *virginica*, quatro variáveis em centímetros e nenhum valor ausente [1].

```
Dimensões: 150 linhas e 4 variáveis preditoras.
```

```
Valores ausentes: 0
```

2 Estatística descritiva

Como as medidas são contínuas, a moda é calculada sobre os valores observados com sua precisão original. Quando há empate, todas as modas são exibidas.

2.1 Resumo geral

Variavel	Media	Desvio_padrao	Moda
Comprimento_sepala	5,843	0,828	5
Largura_sepala	3,057	0,436	3
Comprimento_petala	3,758	1,765	1.4, 1.5
Largura_petala	1,199	0,762	0.2

2.2 Resumo por categoria

Categoria	Variavel	Media	Desvio_padrao	Moda
setosa	Comprimento_sepala	5,006	0,352	5, 5.1
setosa	Largura_sepala	3,428	0,379	3.4
setosa	Comprimento_petala	1,462	0,174	1.4, 1.5
setosa	Largura_petala	0,246	0,105	0.2
versicolor	Comprimento_sepala	5,936	0,516	5.5, 5.6, 5.7
versicolor	Largura_sepala	2,770	0,314	3
versicolor	Comprimento_petala	4,260	0,470	4.5
versicolor	Largura_petala	1,326	0,198	1.3
virginica	Comprimento_sepala	6,588	0,636	6.3
virginica	Largura_sepala	2,974	0,322	3
virginica	Comprimento_petala	5,552	0,552	5.1
virginica	Largura_petala	2,026	0,275	1.8

2.3 Frequência das categorias

Categoria	Frequencia	Percentual
setosa	50	33,3%
versicolor	50	33,3%
virginica	50	33,3%

As classes são perfeitamente balanceadas: cada espécie representa um terço do conjunto. Assim, a acurácia é uma métrica interpretável e não é dominada por uma classe majoritária.

3 Relação entre comprimento e largura da sépala

Categoria	Correlacao_Pearson
setosa	0,743
versicolor	0,526
virginica	0,457

Há sobreposição considerável entre *versicolor* e *virginica* no plano das sépalas. A *setosa* tende a ter sépalas mais curtas e relativamente mais largas. As correlações internas são positivas, mas a separação visual somente com essas duas variáveis é limitada.

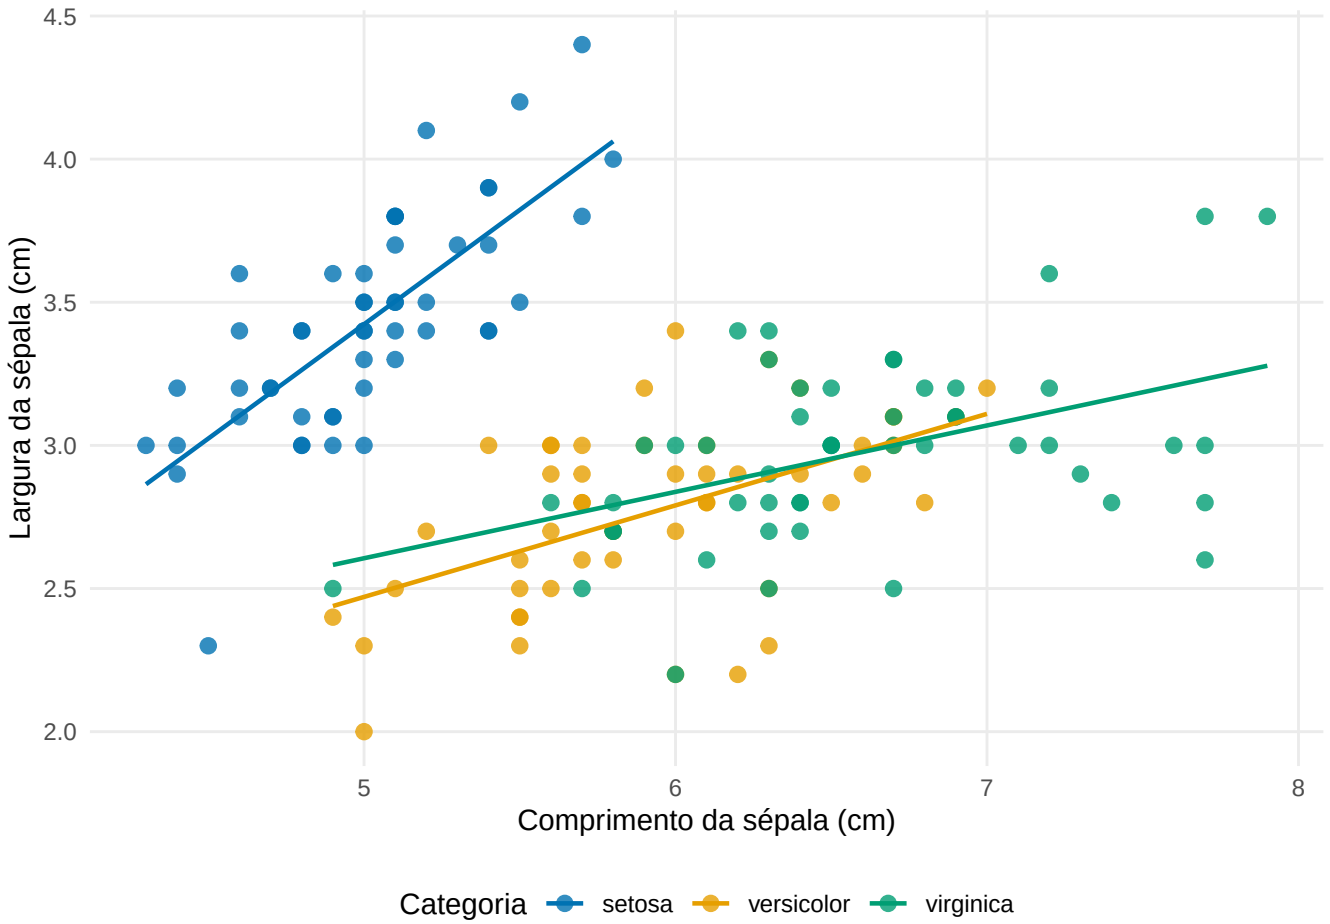


Figura 1: Comprimento e largura da sépala por categoria.

4 Relação entre comprimento e largura da pétala

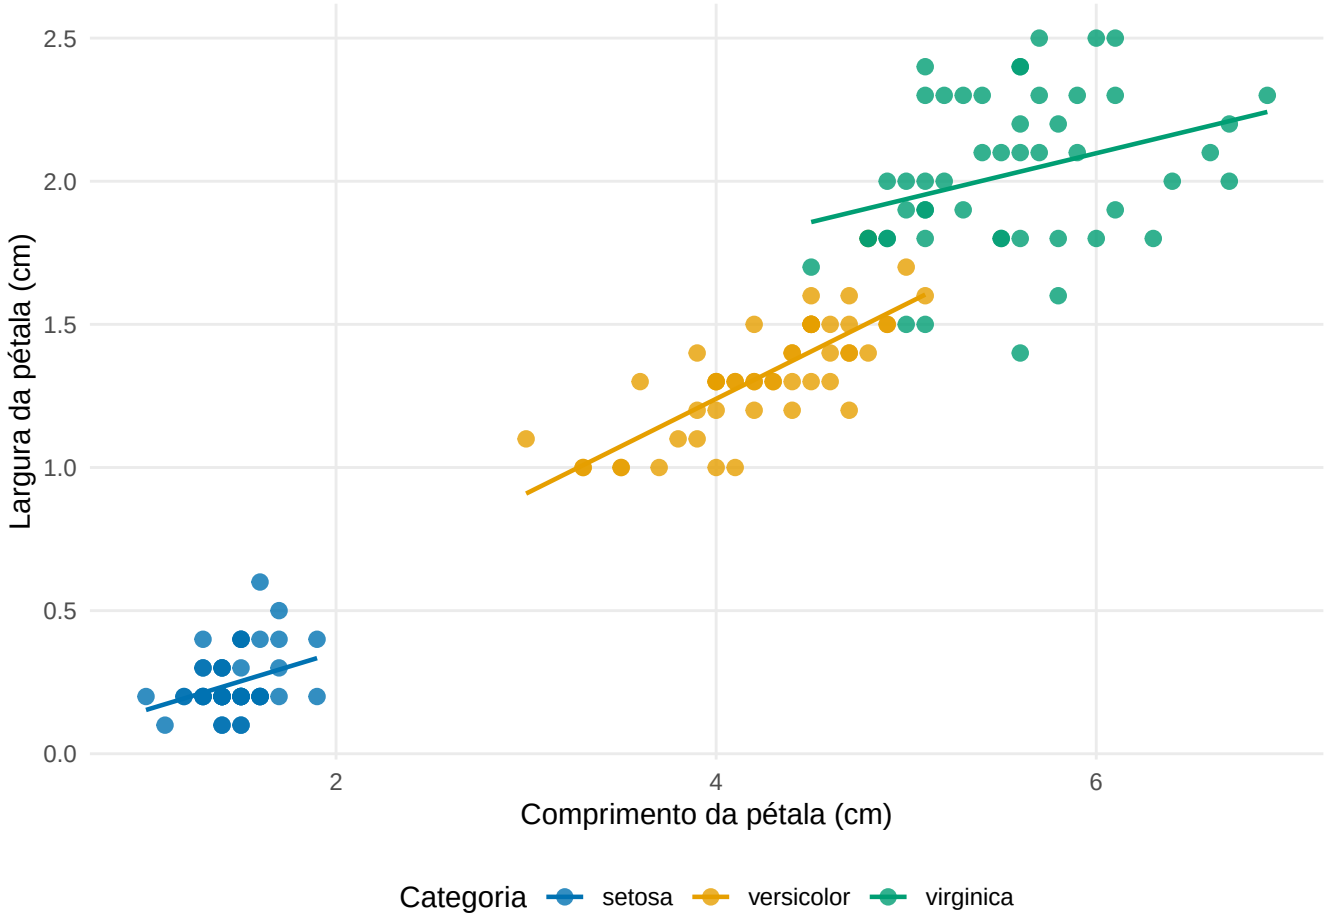


Figura 2: Comprimento e largura da pétala por categoria.

Categoria	Correlacao_Pearson
setosa	0,332
versicolor	0,787
virginica	0,322

As pétalas oferecem separação muito mais clara: *setosa* forma um grupo isolado, enquanto *versicolor* e *virginica* ainda apresentam uma pequena região de sobreposição. Em geral, pétalas mais compridas também são mais largas.

5 Distribuição conjunta nas quatro dimensões

Os pares envolvendo medidas de pétala são os mais discriminativos. Medidas de sépala, especialmente a largura, possuem maior sobreposição. Isso sugere que um classificador que combine as quatro dimensões pode aproveitar a separação das pétalas e usar as sépalas como informação complementar.

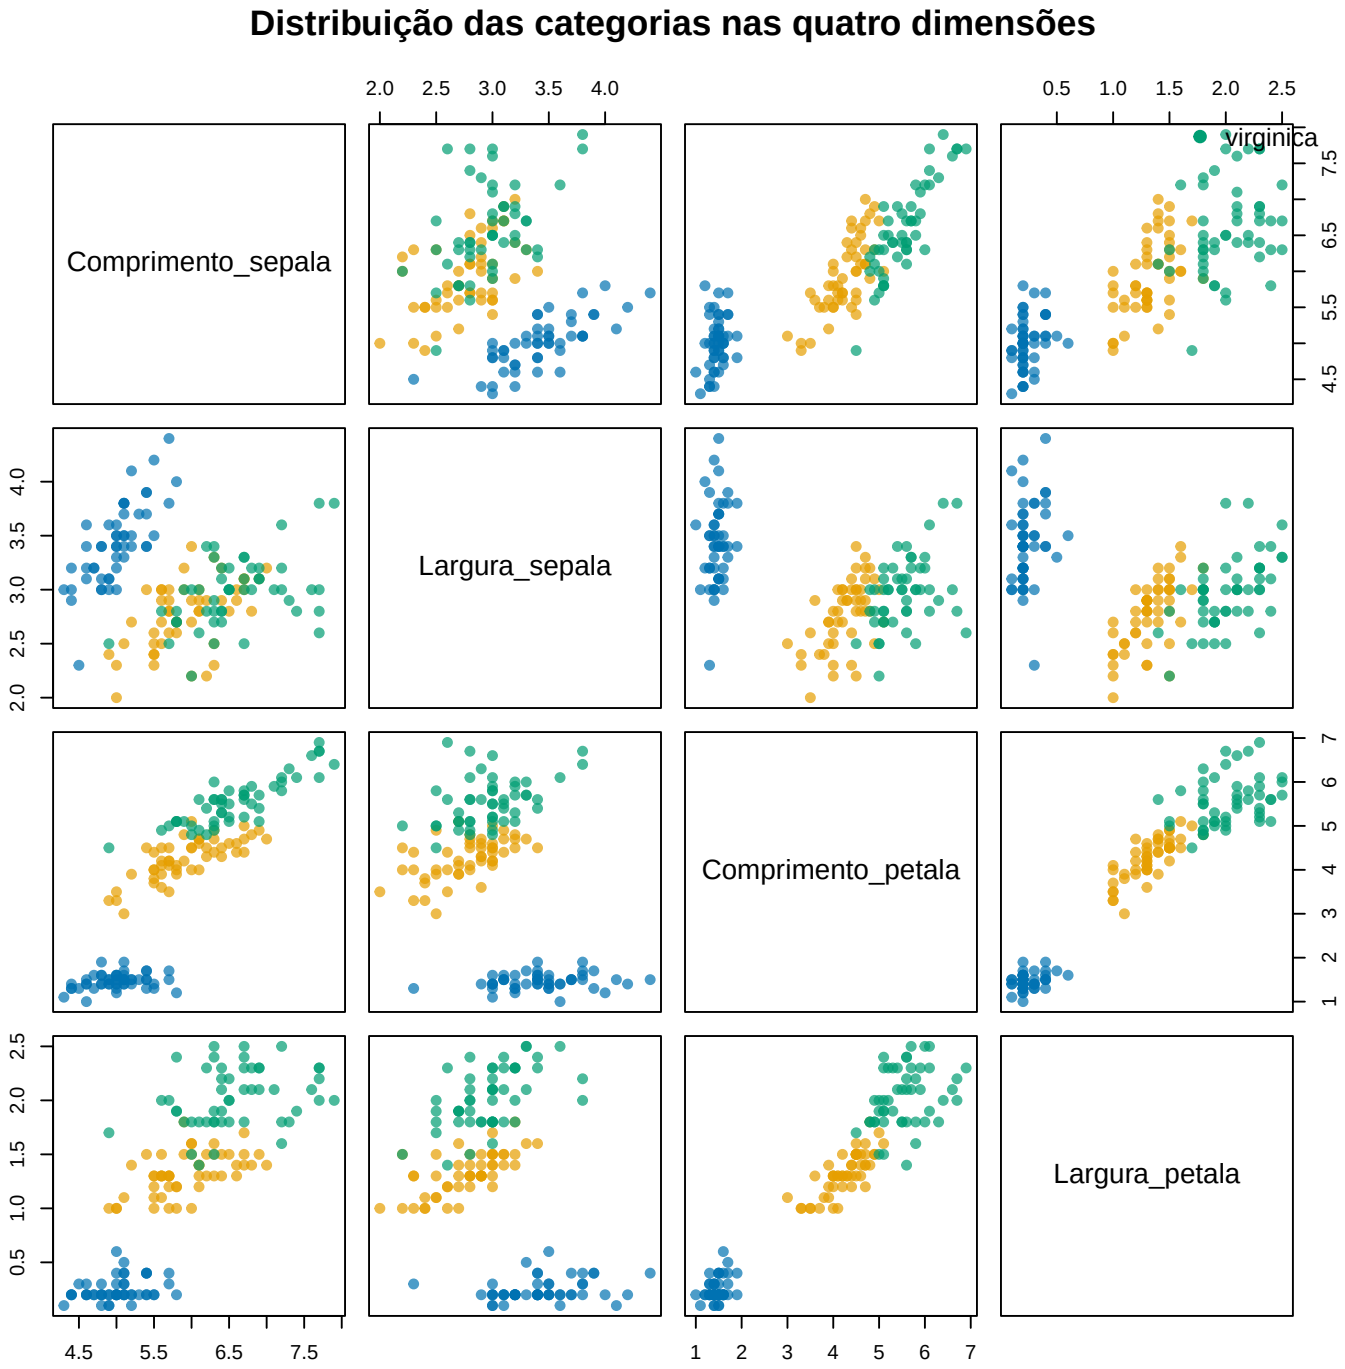


Figura 3: Matriz de dispersão das quatro variáveis.

6 Análise de Componentes Principais (PCA)

PCA transforma variáveis correlacionadas em eixos ortogonais ordenados pela variância explicada [2]. As quatro medidas foram padronizadas antes do cálculo, pois possuem dispersões diferentes. PCA é usado aqui para exploração e visualização, não como parte do ajuste final do K-NN.

Componente	Variancia_explicada	Acumulada
PC1	72,96%	72,96%
PC2	22,85%	95,81%
PC3	3,67%	99,48%
PC4	0,52%	100,00%

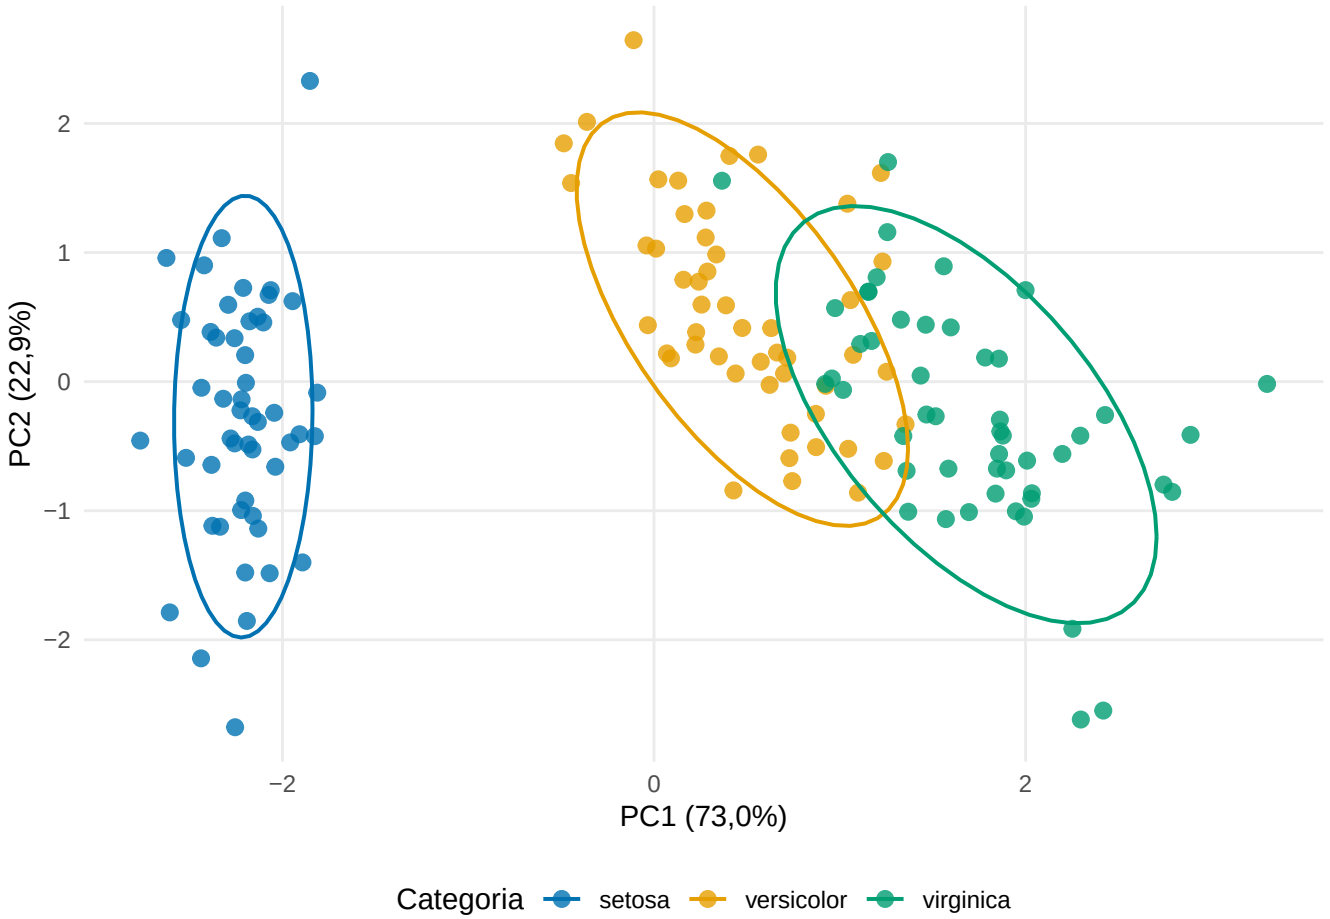


Figura 4: Projeção das amostras nos dois primeiros componentes principais.

	Variavel	PC1	PC2
Comprimento_sepala	Comprimento_sepala	0,521	-0,377
Largura_sepala	Largura_sepala	-0,269	-0,923
Comprimento_petala	Comprimento_petala	0,580	-0,024
Largura_petala	Largura_petala	0,565	-0,067

Os dois primeiros componentes preservam 95,81% da variância total. O PC1 recebe grande contribuição das dimensões das pétalas e do comprimento da sépala, funcionando aproximadamente como um eixo de

"tamanho". O PC2 destaca principalmente a largura da sépala. A projeção 2D mantém *setosa* claramente separada e revela a proximidade entre *versicolor* e *virginica*.

7 Classificação com K-NN

Foi usada divisão estratificada de 80% para treino (120 amostras) e 20% para teste (30 amostras), com semente 42. Cada classe contribui com 40 exemplos para treino e 10 para teste. A padronização usa somente média e desvio do treino. O valor de k é escolhido por validação cruzada estratificada em cinco partes, exclusivamente dentro do treino, entre os valores ímpares de 1 a 15.

k	Acuracia_CV
1	0,950
3	0,933
5	0,967
7	0,950
9	0,967
11	0,958
13	0,958
15	0,950

k escolhido: 5.

	setosa	versicolor	virginica
setosa	9	1	0
versicolor	0	9	1
virginica	0	2	8

Categoria	Precisao	Revocacao	F1
setosa	1,000	0,900	0,947
versicolor	0,750	0,900	0,818
virginica	0,889	0,800	0,842

Acurácia no teste: 86,7%.

8 Conclusão

O dataset é balanceado e apresenta estrutura bastante favorável à classificação. As medidas de pétala são as variáveis que melhor distinguem as espécies; as medidas de sépala isoladamente produzem mais sobreposição. PCA comprime as quatro variáveis em dois eixos mantendo 95,81% da variância e preserva a estrutura visual das classes. Com 5 vizinhos, o K-NN padronizado obteve **86,7% de acurácia** nas 30 amostras de teste. Os eventuais erros ficam entre *versicolor* e *virginica*, justamente as classes que se sobrepõem nos gráficos; *setosa* permanece a classe mais fácil de identificar.

9 Referências

[1] Fisher, R. A. (1936). *Iris* [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C56C76.

[2] Jolliffe, I. T.; Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374:20150202. DOI: 10.1098/rsta.2015.0202.