Bruno Sime Ferreira Nunes – GRR20190568

Classificação das três espécies de Iris com MLP from scratch

Curitiba, PR
2026

Bruno Sime Ferreira Nunes – GRR20190568

Classificação das três espécies de Iris com MLP from scratch

Trabalho acadêmico apresentado como requisito de avaliação na disciplina de Visão Computacional e Percepção da Universidade Federal do Paraná.

Universidade Federal do Paraná (UFPR)
Disciplina de Visão Computacional e Percepção

Orientador: Prof. Eduardo Todt

Curitiba, PR
2026

RESUMO

Este trabalho revisa e depura uma implementação de perceptron multicamadas construída sem bibliotecas de redes neurais e avalia quatro configurações no conjunto Iris. A versão corrigida utiliza propagação vetorizada, softmax, entropia cruzada, inicialização Xavier ou He, mini-batches, regularização L2 e parada antecipada opcional. O protocolo separa os dados de forma estratificada em treino, validação e teste e repete cada configuração com dez inicializações. A configuração regularizada escolhida obteve 96,67% no teste, com um único erro entre *virginica* e *versicolor*. As curvas também mostram que redes capazes de memorizar o treino não necessariamente apresentam melhor generalização.

Palavras-chave: perceptron multicamadas. backpropagation. Iris. convergência. overfitting.

ABSTRACT

This work reviews and debugs a multilayer perceptron implemented without neural-network libraries and evaluates four configurations on the Iris dataset. The corrected version uses vectorized propagation, softmax, cross-entropy, Xavier or He initialization, mini-batches, L2 regularization, and optional early stopping. The protocol uses stratified train, validation, and test partitions and repeats each configuration with ten initializations. The selected regularized model achieved 96.67% test accuracy, with a single error between *virginica* and *versicolor*. The learning curves also show that models capable of memorizing the training data do not necessarily generalize better.

Keywords: multilayer perceptron. backpropagation. Iris. convergence. overfitting.

SUMÁRIO

1 INTRODUÇÃO 5

2 FUNDAMENTAÇÃO TEÓRICA 6
2.1 Perceptron multicamadas 6
2.2 Convergência e generalização 6

3 AUDITORIA E DEPURAÇÃO 7

4 MATERIAIS E MÉTODOS 8
4.1 Conjunto de dados e particionamento 8
4.2 Configurações experimentais 8
4.3 Métricas 8

5 RESULTADOS E DISCUSSÃO 9
5.1 Comparação das configurações 9
5.2 Convergência e overfitting 10
5.3 Resultado por classe 10

6 CONCLUSÃO 12

REFERÊNCIAS 13

1 INTRODUÇÃO

O objetivo deste trabalho é compreender a implementação fornecida de uma rede perceptron multicamadas (MLP), corrigir falhas que comprometiam seu funcionamento e investigar como classificar adequadamente as três espécies do conjunto Iris. O problema contém 150 amostras, quatro atributos contínuos e três classes balanceadas: *setosa*, *versicolor* e *virginica*.

O conjunto é pequeno, mas oferece um caso útil para estudar otimização e generalização. *Setosa* é bem separada pelas medidas das pétalas, enquanto *versicolor* e *virginica* apresentam uma região de sobreposição. Assim, além da acurácia global, é necessário observar a matriz de confusão, as métricas por classe, as curvas de perda e a diferença entre o desempenho de treino e validação.

O notebook-base foi estudado como ponto de partida. A nova implementação preserva o caráter didático do código *from scratch*: a rede, o fluxo direto e o backpropagation utilizam apenas NumPy. Scikit-learn é empregado somente para carregar o conjunto, realizar a divisão estratificada e calcular métricas.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 PERCEPTRON MULTICAMADAS

Para uma entrada $X \in \mathbb{R}^{n\times 4}$, a camada oculta é calculada por

$$Z_1 = XW_1 + b_1, \qquad A_1 = g(Z_1), \tag{2.1}$$

em que g é sigmoid, tangente hiperbólica ou ReLU, conforme a configuração. A camada de saída produz os logits

$$Z_2 = A_1W_2 + b_2. \tag{2.2}$$

Como as classes são mutuamente exclusivas, as probabilidades são obtidas com softmax:

$$p_{ik} = \frac{\exp(z_{ik} - m_i)}{\sum_j \exp(z_{ij} - m_i)}, \qquad m_i = \max_j z_{ij}. \tag{2.3}$$

A subtração de m_i evita overflow sem alterar as probabilidades. A função objetivo combina entropia cruzada e, quando habilitada, penalidade L2:

$$\mathcal{L} = -\frac{1}{n}\sum_{i=1}^{n}\sum_{k=1}^{3} y_{ik}\log(p_{ik} + \varepsilon) + \frac{\lambda}{2}\left(\|W_1\|_F^2 + \|W_2\|_F^2\right). \tag{2.4}$$

2.2 CONVERGÊNCIA E GENERALIZAÇÃO

Convergência é identificada pela redução da função de custo. Entretanto, uma perda de treino continuamente decrescente não garante melhora fora dos dados usados no ajuste. O overfitting ocorre quando o modelo aprende detalhes específicos do treino e perde capacidade de generalização. Neste trabalho, ele é analisado por três sinais: aumento ou estabilização da perda de validação, diferença entre acurácias de treino e validação e desempenho inferior no teste apesar de treino perfeito.

A parada antecipada preserva os pesos da época com menor perda de validação. A regularização L2 limita pesos excessivamente grandes, enquanto a padronização coloca os quatro atributos em escalas comparáveis. Esses mecanismos reduzem a dependência da inicialização e ajudam a controlar o ajuste em um conjunto pequeno.

3 AUDITORIA E DEPURAÇÃO

A inspeção do notebook-base revelou erros de execução e inconsistências entre treinamento e inferência. A Tabela 1 resume os principais pontos.

Tabela 1 – Problemas encontrados e correções aplicadas.

Problema	**Consequência**	**Correção**
`iasHiddenValue` no construtor	Erro ao usar os parâmetros padrão	Nomes dos vieses unificados e inicialização explícita
`predict` sem ativações	Inferência diferente do treinamento	Mesmo fluxo direto em treino, validação e teste
Viés atualizado dentro do laço dos pesos	A mesma correção é aplicada várias vezes	Gradientes vetorizados e uma atualização por lote
Delta oculto calculado após atualizar W_2	O gradiente mistura dois estados da rede	Todos os gradientes são calculados antes das atualizações
Erro quadrático acumulado de modo incorreto	A curva não representa o MSE declarado	Softmax e entropia cruzada calculada por amostra
Sem validação e sem embaralhamento por época	Generalização não é monitorada	Divisão estratificada, shuffle e early stopping

O trecho a seguir mostra a parte central da correção. Primeiro são calculados todos os gradientes; somente depois os parâmetros são atualizados.

Listing 3.1 – Núcleo vetorizado do backpropagation corrigido.

```
z1, a1, probs = self._forward(xb)
dz2 = (probs - yb) / len(xb)
dW2 = a1.T @ dz2 + self.l2 * self.W2
db2 = np.sum(dz2, axis=0, keepdims=True)
dz1 = (dz2 @ self.W2.T) * self._activation_derivative(a1, z1)
dW1 = xb.T @ dz1 + self.l2 * self.W1
db1 = np.sum(dz1, axis=0, keepdims=True)

self.W1 -= self.learning_rate * dW1
self.b1 -= self.learning_rate * db1
self.W2 -= self.learning_rate * dW2
self.b2 -= self.learning_rate * db2
```

4 MATERIAIS E MÉTODOS

4.1 CONJUNTO DE DADOS E PARTICIONAMENTO

O conjunto Iris foi dividido de forma estratificada e determinística: 90 amostras para treino (60%), 30 para validação (20%) e 30 para teste (20%). O teste contém dez exemplos de cada espécie. Quando utilizada, a padronização foi calculada exclusivamente a partir do treino:

$$x' = \frac{x - \mu_{\text{treino}}}{\sigma_{\text{treino}}}. \tag{4.1}$$

Esse procedimento evita vazamento de informação. O conjunto de teste permaneceu separado do ajuste. Cada configuração foi repetida com dez sementes de inicialização para avaliar a variabilidade dos pesos iniciais.

4.2 CONFIGURAÇÕES EXPERIMENTAIS

A arquitetura possui quatro entradas, uma camada oculta e três saídas. Os pesos foram inicializados por Xavier para sigmoid e tanh e por He para ReLU. A Tabela 2 apresenta as quatro configurações.

Tabela 2 – Configurações avaliadas.

Config.	**Camada oculta**	**Padronização**	**Taxa**	**Lote**	**Regularização**
A	5 sigmoid	Não	0,01	1	Nenhuma
B	8 tanh	Sim	0,05	16	Nenhuma
C	12 tanh	Sim	0,05	16	L2 e early stopping
D	64 ReLU	Sim	0,02	8	Nenhuma

As configurações A e B executaram 1.500 épocas. A configuração C tinha limite de 2.500 épocas e paciência de 180 épocas. A configuração D executou 2.500 épocas para investigar o comportamento de uma rede com maior capacidade e sem regularização.

4.3 MÉTRICAS

Foram calculadas acurácia, precisão, recall e F1 por classe. A estabilidade foi medida pelo desvio-padrão da acurácia de teste nas dez inicializações. O gap de generalização corresponde à acurácia de treino menos a acurácia de validação.

5 RESULTADOS E DISCUSSÃO

Este capítulo reúne os resultados quantitativos, as curvas de convergência e a análise dos erros da configuração selecionada.

5.1 COMPARAÇÃO DAS CONFIGURAÇÕES

A Tabela 3 resume as dez inicializações. A configuração A alcançou a maior média de teste, mas também apresentou a maior dispersão e exigiu todas as 1.500 épocas. A configuração C foi adotada para a análise detalhada porque combina regularização explícita, parada antecipada, menor custo médio e uma execução representativa de alta acurácia.

Tabela 3 – Resultados médios das dez inicializações.

Config.	**Teste (%)**	**Treino (%)**	**Validação (%)**	**Gap (p.p.)**	**Épocas**
A	$95{,}67 \pm 3{,}53$	97,44	99,00	-1,56	1.500,0
B	$90{,}33 \pm 1{,}05$	100,00	96,67	3,33	1.500,0
C	$95{,}00 \pm 1{,}76$	99,00	93,33	5,67	457,4
D	$93{,}33 \pm 0{,}00$	100,00	96,67	3,33	2.500,0

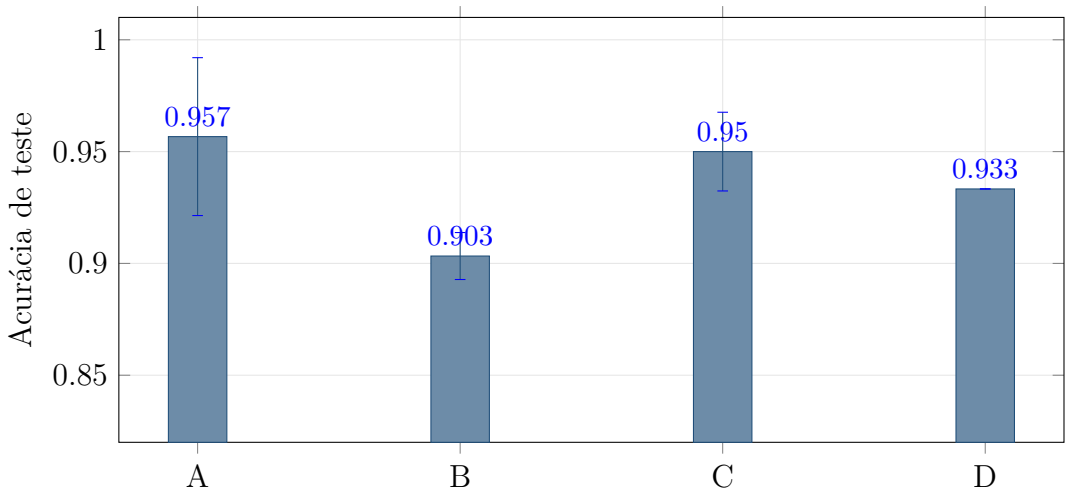


Figura 1 – Acurácia média de teste e desvio-padrão em dez inicializações.

A configuração A variou de 90% a 100%, mostrando sensibilidade à inicialização. A configuração C apresentou menor dispersão e encerrou o treinamento após 457,4 épocas em média, aproximadamente 82% abaixo do limite máximo de 2.500 épocas.

5.2 CONVERGÊNCIA E OVERFITTING

A Figura 2 compara uma execução sem regularização, configuração B, à configuração C. Em B, a perda de treino continua caindo após 200 épocas, enquanto a perda de validação atinge o mínimo e passa a crescer. Esse é um sinal direto de overfitting. Em C, a penalidade L2 suaviza o ajuste e o early stopping recupera os parâmetros correspondentes à melhor perda de validação.

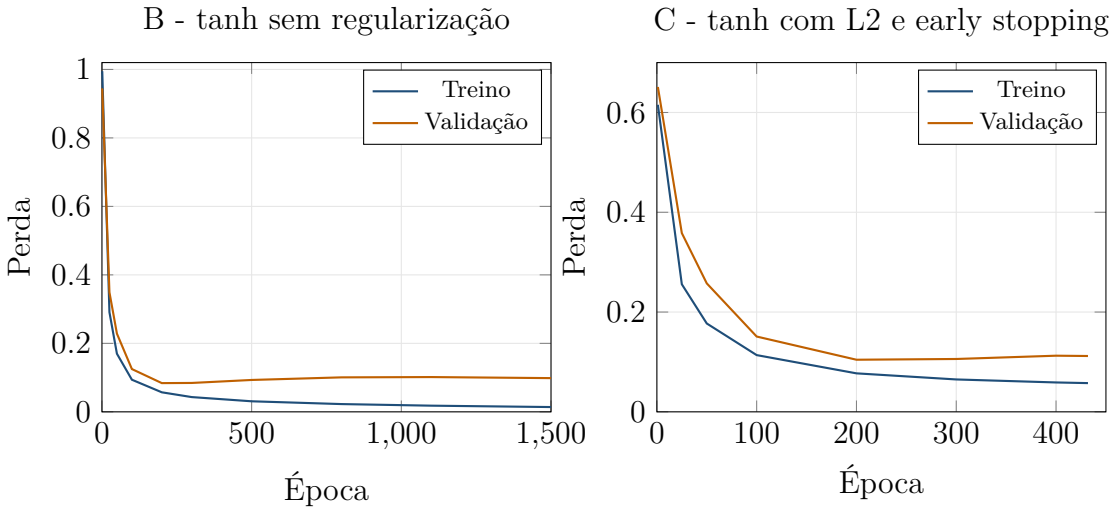


Figura 2 – Curvas de perda para execuções representativas com semente 7.

A rede grande D atingiu 100% de acurácia no treino, mas obteve 93,33% no teste. Portanto, aumentar a capacidade e prolongar o treinamento não trouxe ganho de generalização. A configuração C também apresentou um gap treino-validação, mas seu desempenho de teste foi mais alto e o processo foi interrompido muito antes do limite.

5.3 RESULTADO POR CLASSE

Na execução representativa da configuração C, com semente 7, a acurácia de teste foi 96,67% e o F1 macro foi 0,9666. A matriz de confusão é apresentada na Figura 3.

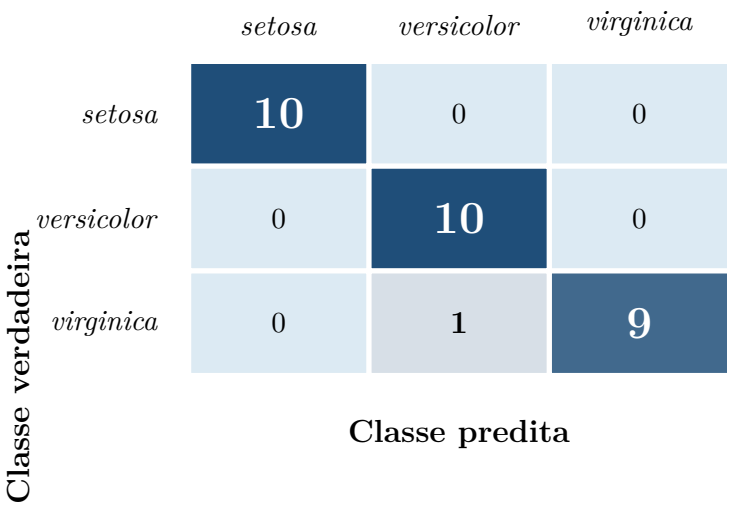


Figura 3 – Matriz de confusão da configuração C, semente 7.

Tabela 4 – Métricas por classe da configuração selecionada.

Classe	**Precisão**	**Recall**	**F1**	**Suporte**
setosa	1,0000	1,0000	1,0000	10
versicolor	0,9091	1,0000	0,9524	10
virginica	1,0000	0,9000	0,9474	10
Macro	0,9697	0,9667	0,9666	30

Todas as amostras de *setosa* e *versicolor* foram reconhecidas. O único erro foi uma *virginica* classificada como *versicolor*, com confiança de 0,7059. A amostra possui comprimento e largura de sépala iguais a 6,3 cm e 2,8 cm e comprimento e largura de pétala iguais a 5,1 cm e 1,5 cm. Esse perfil está próximo da região de sobreposição das duas espécies e explica a confusão.

Como o teste contém apenas 30 exemplos, um único erro altera a acurácia em 3,33 pontos percentuais. Por isso, a repetição de sementes e a análise por classe são necessárias para interpretar o desempenho sem depender de uma única porcentagem.

6 CONCLUSÃO

A depuração corrigiu o construtor, tornou o fluxo de inferência consistente com o treinamento, reorganizou o cálculo dos gradientes, eliminou atualizações repetidas dos vieses e substituiu a medida de erro incorreta por softmax com entropia cruzada. A implementação final manteve a proposta *from scratch* e tornou os experimentos reproduzíveis.

A MLP regularizada selecionada classificou adequadamente as três espécies e atingiu 96,67% no teste, errando somente uma amostra na fronteira entre *versicolor* e *virginica*. A análise de convergência mostrou que a perda de treino, isoladamente, é insuficiente: as configurações B e D memorizaram o treino, mas não produziram o melhor teste.

Para o conjunto Iris, uma única camada oculta de capacidade moderada, softmax, entropia cruzada, inicialização apropriada, regularização L2 e monitoramento da validação oferecem uma solução simples e eficaz. Trabalhos futuros podem usar validação cruzada estratificada para reduzir a sensibilidade causada pelo tamanho reduzido do conjunto de validação.

REFERÊNCIAS

[1] FISHER, R. A. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, v. 7, n. 2, p. 179–188, 1936.

[2] GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016.

[3] LEMOS, V. G. *Multilayer Perceptron from Scratch*. Notebook de referência adaptado no material da disciplina. Disponível em: https://www.kaggle.com/code/vitorgamalemos/multilayer-perceptron-from-scratch. Acesso em: 18 out. 2026.

[4] SCIKIT-LEARN DEVELOPERS. *Iris plants dataset*. Disponível em: https://scikit-learn.org/stable/datasets/toy_dataset.html#iris-dataset. Acesso em: 18 out. 2026.